

# 大连理工大学本科毕业论文

## 基于深度学习的食管炎检测方法研究与实现

### Research and Implementation of Esophagitis Detection Method Based on Deep Learning

学 院（系）：电子信息与电气工程学部

专 业：计算机科学与技术专业

学 生 姓 名：王可晴

学 号：201988007

指 导 教 师：杨鑫

评 阅 教 师：申彦明

完 成 日 期：2023.06.03

大连理工大学

Dalian University of Technology

## 原创性声明

本人郑重声明：本人所呈交的毕业论文（设计），是在指导老师的指导下独立进行研究所取得的成果。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。除文中已经注明引用的内容外，不包含任何其他个人或集体已经发表或撰写过的科研成果。对本文的研究成果做出重要贡献的个人和集体，均已在文中以明确方式标明。

本声明的法律责任由本人承担。

作者签名：

日 期：

## 关于使用授权的声明

本人在指导老师指导下所完成的毕业论文（设计）及相关的资料（包括图纸、试验记录、原始数据、实物照片、图片、录音带、设计手稿等），知识产权归属大连理工大学。本人完全了解大连理工大学有关保存、使用毕业论文（设计）的规定，本人授权大连理工大学可以将本毕业论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用任何复制手段保存和汇编本毕业论文（设计）。如果发表相关成果，一定征得指导教师同意，且第一署名单位为大连理工大学。本人离校后使用毕业毕业论文（设计）或与该论文直接相关的学术论文或成果时，第一署名单位仍然为大连理工大学。

论文作者签名：

日 期：

指导老师签名：

日 期：

## 摘 要

食管炎是一种常见的消化系统疾病，其诊断和治疗一直是医学工作者所关注的热点问题。随着深度学习技术的发展，基于深度学习的图像分割技术在医学图像处理中逐渐发挥着越来越重要的作用。

本研究基于 UNet++ 和 DeepLabv3+ 分别构建了用于食管炎炎症部位分割的深度学习模型，以期在完成任务的基础上对两者进行横向对比。在模型训练方面，本研究采用了大连中心医院所提供的患者食管炎数据来进行模型的训练；在模型评估方面，研究结果表明，基于深度学习的食管炎检测方法能够有效地将食管炎症部位从图像中分割出来，达到较高的准确性和精度。

值得注意的是，相较于 UNet++ 模型，DeepLabv3+ 模型在病变区域的边缘检测上表现更好。通过对这两个模型全面的模型评估，本研究归纳总结了 UNet++ 和 DeepLabv3+ 两个模型在解决同一食管炎分割问题时各自的优势和特点，为深度学习在食管炎检测方面的应用提供参考性的建议。

总之，本研究基于深度学习技术搭建了有效的 AI 模型，该模型能够在食管炎患者的食管照片上实现对炎症部位的准确分割。该研究结果为食管炎的诊断和治疗提供了有力的支持和保障，同时也拓展了深度学习在医学图像处理中的应用。未来，本研究所提出的方法也可以进一步被完善和优化，以应对其他的医学图像分割挑战。

**关键词：深度学习；食管炎检测；图像分割；UNet++；DeepLabv3+**

## Research and Implementation of Esophagitis Detection Method Based on Deep Learning

### Abstract

Esophagitis is a common digestive system disease, and its diagnosis and treatment have always been a hot topic of concern to medical workers. With the development of deep learning technology, image segmentation technology based on deep learning is gradually playing an increasingly important role in medical image processing.

In this study, based on UNet++ and DeepLabv3+, a deep learning model for esophagitis inflammation site segmentation was constructed respectively, in order to compare the two horizontally on the basis of completing the task. In terms of model training, this study uses the data of patients with esophagitis provided by Dalian Central Hospital for model training; in terms of model evaluation, the research results show that the esophagitis detection method based on deep learning can effectively distinguish the esophageal inflammation site from The image is segmented out to achieve high accuracy and precision.

It is worth noting that, compared with the UNet++ model, the DeepLabv3+ model performs better on the edge detection of the lesion area. Through a comprehensive model evaluation of these two models, this study summarizes the different advantages and characteristics of the two models UNet++ and DeepLabv3+ in solving the same esophagitis segmentation problem, and provides a basis for the application of deep learning in the detection of esophagitis. Informative suggestions.

In short, this study built an effective AI model based on deep learning technology, which can accurately segment the inflammatory site on the esophagus photos of patients with esophagitis. The results of this study provide strong support and guarantee for the diagnosis and treatment of esophagitis, and also expand the application of deep learning in medical image processing. In the future, the method proposed in this study can also be further improved and optimized to deal with other medical image segmentation challenges.

**Key Words: Deep learning; Esophagitis Detection; Image Segmentation; UNet++; DeepLabv3+**

## 目 录

摘    要 .....	I
Abstract .....	II
引    言 .....	1
1 研究背景与意义 .....	5
1.1 研究背景 .....	5
1.2 研究目的 .....	5
1.3 研究意义 .....	6
1.4 主要研究内容 .....	7
1.5 本文组织架构 .....	8
2 算法流程概述 .....	10
2.1 算法总体概述 .....	10
2.1.1 U-Net 算法概括 .....	10
2.1.2 UNet++算法概括 .....	11
2.1.3 DeepLabv3 算法概括 .....	12
2.1.4 DeepLabv3+算法概括 .....	14
2.1.5 UNet++网络与 DeepLabv3+网络比较与分析 .....	14
2.2 算法评估指标 .....	16
2.2.1 IoU 指标 .....	16
2.2.2 mPA 指标 .....	16
2.2.3 Accuracy 指标 .....	16
2.3 算法训练参数 .....	17
2.3.1 UNet++核心训练参数 .....	17
2.3.2 DeepLabv3+核心训练参数 .....	17
3 模型训练与评估 .....	19
3.1 基于 UNet++的模型训练与评估 .....	19
3.1.1 模型搭建步骤 .....	19
3.1.2 数据预处理 .....	19
3.1.3 模型配置 .....	20
3.1.4 模型训练 .....	21
3.1.5 模型评估 .....	22
3.2 基于 DeepLabv3+的模型训练与评估 .....	24

3.2.1	模型搭建步骤.....	24
3.2.2	数据预处理.....	24
3.2.3	模型配置.....	24
3.2.4	模型训练.....	25
3.2.5	模型评估.....	27
3.3	评估结果分析.....	28
4	总结与展望.....	29
4.1	本文工作总结.....	29
4.2	本文工作展望.....	29
结 论	.....	31
参 考 文 献	.....	32
修改记录	.....	34
致 谢	.....	35

## 引言

食管炎是一种常见的疾病，它的发生可能会导致患者表现出吞咽困难、胸痛、消化不良等症状，严重时甚至可能会影响患者的生命质量<sup>[1]</sup>，其检测方法主要可以分为两类：传统图像处理方法和深度学习方法。传统的食管炎诊断通常依靠人工观察，这种方法存在着诊断准确性差、时间成本高、人为误差大等问题。而近年来快速发展的深度学习技术可以通过大量数据的学习训练进行模式识别，在图像识别、语音识别等任务中有着出色的表现，这表明其有完成食管炎分割任务的潜力。与前者相比，基于深度学习的食管炎检测方法能够有效克服传统食管炎检测方法对人工经验和图像处理技术的依赖，提高食管炎诊断的准确性和效率。基于上述优势，基于深度学习的自动化食管炎检测方法的开发是一个切实可行的研究方向，其开发具有必要性和现实意义。

当前，国内外已有多项基于深度学习的医学分割问题的相关研究。其中，卷积神经网络（Convolutional Neural Network），循环神经网络（Recurrent Neural Network）和深度信念网络（Deep Belief Network）是这类分割模型常用的网络结构。这些 AI 模型的评估结果表明，基于深度学习的方法能够有效地提高医学图像分割的检测准确性和效率。接下来，本文将详细介绍国内外研究者在这一领域的研究历史和现状。

在国内，早期的医学诊断主要依靠人工检查，该方法具有精度高和直观的优点，但操作复杂，不适用于大规模筛查和早期诊断；此后，国内的医学疾病检测研究开始引入计算机辅助诊断技术，利用图像处理技术和机器学习技术如边缘检测、纹理特征提取和分类器等进行辅助诊断，但这些方法往往需要手工设计特征和分类器，模型的性能仍受到一定的限制；近年来，许多研究者和团队开始关注深度学习在医学图像分割领域的应用，并进行了大量的研究和实验，以下是一些国内研究者在这一研究方向的成果。

Hua 等人<sup>[2]</sup>首次创新性地将深度学习应用于肺结节的分类问题，通过引入深度信念网络和卷积神经网络对肺结节的良性和恶性进行分类。深度信念网络是一种用于无监督学习的深度神经网络模型，由多层受限玻尔兹曼机组成。它可以自动学习输入数据的特征，并在学习过程中对数据进行降维，这些特点提高了该网络处理大型数据集的效率。与其他深度神经网络模型相比，深度信念网络在处理高维数据时表现出色，其特点在于其可以在无监督预训练过程中发掘数据中的高阶特征，并通过逐层迭代学习抽象出更加复杂的特征，从而提高分类准确率。研究结果表明，基于深度学习的肺结节分类方法的灵敏度和特异性都远高于基于特征计算的方法，取得了较好的临床效果。

随后，Cheng 等人<sup>[3]</sup>也就此展开相关研究，基于堆栈式去噪自编码器（Stacked Denoising Auto-encoder）开发算法以解决 CT 图像的肺结节分割问题。堆栈式去噪自编



码器是一种基于深度学习的无监督学习方法，由多个自编码器组成，每个自编码器都是一个三层的神经网络——输入层、隐藏层和输出层。其中，输入层和输出层的神经元数量相同，而隐藏层的神经元数量通常比前两者更少。相比于传统的降维方法如主成分分析和线性判别分析等，堆栈式去噪自编码器在处理非线性问题时具有更强的表达能力和更好的鲁棒性。研究表明，基于深度学习的堆栈式去噪自编码器算法能够较好地适应存在固有噪声的医学图像分割问题，所达到的效果比传统的降维方法更好。

在脑肿瘤图像分割方面，国内研究者也进行了相关探索。Zhang 等人<sup>[4]</sup>在研究中提出了一种基于卷积神经网络的方法，通过提取图像块并整合多模态 MRI 图像进行婴儿脑结构的分割。研究表明，与使用支持向量机和随机森林的方法相比，该卷积神经网络算法的分割效果更优。这是因为卷积神经网络可以在整合多模态脑图像的基础上提取更多的特征信息，从而更加准确地分割婴儿的正常脑结构。这种方法可以为临床医生提供更可靠的分割结果，有助于早期疾病的诊断和治疗。

总的来说，国内的研究者已成功地将深度学习技术应用于医学图像分析的相关研究中。研究表明，基于深度学习的医学图像分割算法总体优于传统方法，并且更能适应具有噪声的医学图像，具有准确分类和分割医学图像的潜力。尽管基于深度学习的图像分割方法存在例如如何更好地完成复杂情景下的分类分割任务等问题，但是仍有着广阔的应用前景，相信未来将会有更多的国内研究者和团队投入到该领域的研究中，推动深度学习技术在医学领域的不断创新和拓展。

与此同时，应用于医学领域的深度学习技术在国外也得到了快速的发展。国外研究者们基于卷积神经网络等广泛地进行了医学检测模型的开发，取得了许多令人瞩目的成果，实现了医学图像的高效识别及分割。此外，为了进一步提升模型的效果，研究者们还设计了一系列的模型优化方法。例如，一些研究者尝试使用强化学习来自适应地调整网络结构和参数，并取得了较为理想的效果。以下是一些国外研究者在基于深度学习的医学图像分割这一课题上的研究成果。

Ciampi 等人<sup>[5]</sup>提出了一种基于多流和多尺度卷积神经网络的深度学习系统，可以基于原始 CT 图像自动对肺结节进行分类。类似地，Liauchuk 等人<sup>[6]</sup>创新性地采用 GoogLeNet CNN 检测肺结节并绘制受试者工作特征（Receiver Operating Characteristic）曲线。GoogLeNet CNN 是谷歌公司开发的一种用于图像分类任务的卷积神经网络架构，其关键特点是深而窄的架构，通过同时使用 1x1、3x3 和 5x5 的卷积滤波器并连接它们的输出来实现图像分类，这使得网络可以在多个尺度上捕捉特征，同时保持相对较低的参数数量。此外，GoogLeNet CNN 使用一种称为 Inception 模块的新型组件，它是多个不同尺度的卷积滤波器和池化操作的组合。研究表明，基于该网络检测的工作特征

曲线下面积 (Area Under Curve) 为 0.969, 而传统基于特征的方法的曲线下面积为 0.895, 这展示了深度学习技术在医学图像处理问题中准确分类和检测肺结节的潜力, 并为未来基于深度学习的肺结节检测系统的开发提供了有价值的经验和参考。

在脑肿瘤诊断的研究领域中, 医学图像处理的问题变得更加复杂。为了进行准确的病情诊断, 医学工作者需要提取成像中的生物标志物的最大直径、体积和数量等特征来量化疾病, 而这些生物标志物的提取依赖于对肿瘤的准确分割。为此, 国外研究者们利用深度学习方法提出了一些基于卷积神经网络的自动化脑肿瘤分割方法。例如, Havaei 等人<sup>[7]</sup>提出了一种基于卷积神经网络的全自动脑肿瘤分割方法, 该架构可以充分利用图像的局部和全局特征, 同时把卷积的全连接层作为网络的最后一层, 从而将模型的运行速度提高 40 倍。此外, Pereira 等人<sup>[8]</sup>提出了一种基于卷积神经网络的神经胶质瘤分割方法, 他们采用了更小的卷积核以及更深的网络结构, 以此降低网络的过拟合程度和参数数量。该模型在 BRATS 2015 挑战赛中获得第二名, 这展示了其在脑肿瘤分割领域较好的分割效果。上述这些方法的出现为基于深度学习的脑肿瘤分割提供了有力的工具, 对该领域的研究具有重要意义。

除此之外, 在其他医学图像分割的问题上, 利用深度学习算法协助医学诊断的相关研究也卓有成效。例如, 作为女性最常见的癌症之一, 乳腺癌在全球癌症中占比高达 22.9%。因此, 利用医学影像技术对乳腺癌进行早期检测对该疾病的预防和治疗至关重要<sup>[9]</sup>。为了开发出更加高效的乳腺癌分割模型, Dhungel 等人<sup>[10]</sup>采用了结构化支持向量机 (Structured Support Vector Machine) 与深度学习相结合的方法来分割乳腺肿块。与传统支持向量机处理标量预测不同, 结构化支持向量机可以处理多维、结构化的输出。在该支持向量机中, 输入是一组特征向量, 而输出是具有结构的变量, 例如序列标注或图像分割结果。与传统的支持向量机一样, 结构化支持向量机将特征向量映射到一个高维空间中, 并寻找一个超平面将训练样本分开。研究表明, 这种方法可以有效提高 AI 模型在乳腺图像分割任务中所达到的准确性和有效性。

总的来说, 国外研究者对基于深度学习的医学影像分析这一课题进行了广泛的探索, 在肺结节、脑肿瘤和乳腺肿块分割等方面成功应用了该技术并取得了不错的效果。结果表明, 基于深度学习的医学图像处理所达到的准确度和效率相较于传统的人工标注和基于特征的方法均有显著提高, 这展示了神经网络在医学图像分割和分类方面的优越性。同时, 这些国外研究案例也为未来进一步开展基于深度学习的医学图像分割相关研究提供了参考性的经验, 为提高医学诊断的准确性和效率带来了新的可能。

综上可得, 国内外在基于深度学习的医学图像处理问题上的研究历程虽然不尽相同, 但都在不断地探索和发展其在医学图像分类和分割领域的应用, 并且都尝试在传统

医学检测方法的基础上加入计算机技术进行辅助,未来有望实现更加智能和高效的医学诊断。因此,基于深度学习的食管炎检测方法具有其研究可行性和必要性,其有望进一步拓展深度学习技术在医学图像分割领域的应用,提升食管炎诊断的精确性和效率。

本次毕业论文的研究学习内容主要集中在探究基于深度学习的食管炎检测方法,该方法利用 UNet++和 DeepLabv3+分别搭建食管炎分割模型,并利用数据增强和模型优化等方法提升模型分割性能。最后,对这两个模型在实际食管照片上的炎症分割效果进行全面评估,分别分析其模型特点,效果和应用场景。总体目标是通过本研究实现高质量的食管炎图像分割,并为深度学习在医学图像处理方面提供具有参考价值的研究结果和研究经验。

在数据集方面,本研究采用了大连中心医院所提供的高质量食管炎数据集,通过预处理和训练测试集的合理划分来进行分割模型的训练和评估。值得注意的是,在实际操作中,食管炎病变形态各异,包括溃疡、炎症和狭窄等,这些形态上的差异给图像分割带来了很大的挑战;另外,由于食管内部环境复杂,图像中存在大量的噪声和伪影,这些因素会对食管炎图像分割的准确性造成很大的影响。因此,本研究通过对数据集进行合适的预处理来尽可能降低这些因素对分割效果的影响,最终达到了较为满意的食管炎分割效果。

最终,在大连中心医院所提供的食管炎数据集上进行的实验验证表明,本研究所开发的 AI 模型在食管炎分割识别方面具有优越性,能够达到较高的分割精度。总之,本文的主要研究集中在食管炎图像的炎症部位分割,并利用 UNet++和 DeepLabv3+两个深度学习网络分别进行模型搭建。在食管炎图像分割任务中,上述 AI 模型能够比传统的人工标注实现更高的效率和性能,具有重要的实际应用价值。

## 1 研究背景与意义

### 1.1 研究背景

食管炎是一种常见的消化道疾病，它通常由食管黏膜的炎症、损伤或溃疡引起。食管炎的早期检测和准确诊断对于治疗和预防并发症至关重要。传统的食管炎检测方法主要依赖于内镜检查，但这种方法具有侵入性、昂贵和需要专业技能的缺点。随着深度学习技术的快速发展，基于计算机视觉的食管炎检测方法受到了广泛关注。其中，U-Net 和 DeepLabv3 是两个在医学图像分割领域表现出色的核心模型。

U-Net 是一种经典的卷积神经网络结构，具有编码器和解码器相结合的特点。它通过将图像进行逐层下采样和上采样操作，实现对图像特征的有效提取和重建。在食管炎检测中，U-Net 能够捕捉到食管黏膜的细微特征，辅助医生准确地识别炎症区域。DeepLabv3 则是一种基于空洞卷积的深度学习模型，其主要优势在于能够保持分割结果的细节信息。通过在卷积层中引入不同的空洞率，DeepLabv3 能够扩大感受野，从而在保持分割精度的同时提高图像细节的保留能力。在食管炎检测过程中，DeepLabv3 相比于 U-Net 可以更好地捕捉到食管黏膜病变的细微变化，提高检测的准确性；但相应的，DeepLabv3+的网络复杂度更高，运行速度更慢。

综上所述，通过应用 U-Net 和 DeepLabv3 等核心网络，模型可以更好地从食管炎相关图像中提取特征并进行分割，从而辅助医生进行早期检测和诊断。这有助于改善食管炎患者的治疗和预后、减少内镜检查的负担，具有重要的临床应用前景。

### 1.2 研究目的

当今医疗领域中，基于深度学习的医学图像分析已成为热门研究领域之一。食管炎作为一种常见病症，其早期的诊断和治疗至关重要。因此，开发基于深度学习的自动化食管炎检测方法是一种具有潜力的研究方向。本课题的研究目的是开发基于深度学习的食管炎检测方法，通过提供一种自动化的食管炎诊断工具以提升食管炎检测和诊断的效率和精度。具体而言，本研究的目的包括以下几个方面：

(1) 优化食管炎的早期检测环节：通过利用深度学习模型 U-Net 和 DeepLabv3 来识别食管炎相关图像中的炎症区域，提早发现食管炎病变的早期症状并提前进行治疗和干预，从而减轻患者的痛苦，降低相关并发症的风险。

(2) 提高食管炎的诊断准确性：传统的食管炎诊断方法可能存在主观性和操作技巧方面的差异。相比之下，深度学习模型能够自动学习特征并进行图像分割，通过量化和量化分析炎症区域，提高食管炎的诊断准确性，减少误诊和漏诊的发生。

（3）提供辅助决策工具：深度学习模型生成的注意力热点图等可视化成果能够直观地显示模型对食管炎图像中不同区域的关注程度，帮助医生理解模型的决策过程，辅助临床决策和治疗方案的制定。

（4）减少侵入性检查的需求：传统的食管炎诊断主要依赖于内镜检查，具有侵入性、不适和昂贵等缺点，而基于深度学习的食管炎检测方法可以通过分析图像数据进行非侵入性的诊断，降低患者的不适和检查的负担。

综上所述，该研究的目的是通过基于深度学习开发食管炎检测方法，从而提供一种准确、快速且非侵入性的诊断工具，以改善食管炎患者的治疗效果和生活质量。

### 1.3 研究意义

在医学领域，医学影像诊断一直是一项重要的任务。随着深度学习技术的发展，深度学习算法在医学影像分析中得到了广泛应用。以食管炎检测为例，传统的食管炎检测方法依赖人工进行影像分析和诊断，如图 1.1、1.2 所示，由高年资医生手动将食管照片中对应的炎症位置高亮标记出来，效率低下、准确度不高。相比之下，本课题所研究的基于深度学习的食管炎检测算法可以利用大量医学影像数据对模型进行训练，从而建立高效准确的食管炎诊断模型，提高食管炎的检测效率和准确度，为临床医生提供更好的诊断工具。



图 1.1 食管炎实拍照片，由大连中心医院提供




图 1.2 根据照片手工标记的食管炎信息，由大连中心医院提供

除此之外，本课题所研究的深度学习技术还可以应用于其他图像分割任务，具体列举如下：

（1）自动驾驶：深度学习图像分割技术可用于自动驾驶系统中，例如检测和分割道路、行人、车辆等目标。通过实时识别车身附近的车辆及物体，自动驾驶汽车可以更好地避免意外碰撞，保证行车安全。

（2）农业生产：深度学习图像分割技术可用于农业生产中，例如协助工作人员识别作物类型和病害情况等。通过快速分析农田中的图像数据，生产者可以更好地掌握农业生产的状态和进程，提高生产效率。

（3）工业自动化：深度学习图像分割技术可用于工业自动化中，例如检测和分割工业机器人操作中的目标物体。通过实时识别周围环境的物体，技术人员可以更好地指导机器人的操作过程，提高生产效率和精度。

（4）地理信息系统：深度学习图像分割技术可用于地理信息的采集分析中，例如卫星图像的识别和分割，从而更好地识别不同区域的地形和用途。这可以为城市规划、土地利用和资源开发等领域提供更准确的数据支持。

综上所述，基于深度学习的食管炎检测方法这一课题涉及到众多领域和应用场景，这些领域和场景对于高精度、高效率的图像识别和分割提出了需求。因此，研究基于深度学习的食管炎检测方法具有重要意义和广泛的应用前景。

## 1.4 主要研究内容

该课题的主要设计任务及要求包括以下几个方面：

(1) 数据采集和预处理：采集大量食管炎影像数据并对数据进行预处理和标注。预处理包括图像的去噪、增强和标准化等，以便于后续深度学习算法的训练和评估。

(2) 网络设计和优化：选择 UNet++ 和 DeepLabv3+ 这两个在医疗领域常用的深度学习网络进行模型搭建。针对食管炎检测这一具体应用场景对这两个模型进行优化，以提高检测准确度和效率。

(3) 模型搭建和训练：选用合适的编程语言和深度学习框架，实现 UNet++ 和 DeepLabv3+ 这两个深度学习算法的相关代码，并进行训练和调优，以达到较高的炎症区域检测精度。

(4) 模型调试和完善：将训练好的深度学习模型应用于实际的医学影像数据，根据其检测效果进行进一步的调试和完善，以提升食管炎的自动化检测和诊断效果。

(5) 模型评估和分析：对调试后的深度学习模型进行实验评估，包括模型的准确度、召回率、精确度等指标。同时，将基于 UNet++ 和 DeepLabv3+ 的两个模型进行横向对比，验证不同深度学习算法在食管炎影像分割中的优劣和可行性。

通过以上任务的完成，该课题将基于 UNet++ 和 DeepLabv3+ 搭建食管炎检测的深度学习模型，并将这两个模型的 IoU (Intersection over Union) 指标提升到 60% 以上。同时，比较分析这两个模型在食管炎检测任务中的效果和优劣，并根据研究结果提出优化深度学习在食管炎检测方面应用效果的建议。

## 1.5 本文组织架构

本次毕业设计主要围绕基于深度学习的食管炎检测方法展开，分为四个部分，深入研究了自动化食管炎炎症部位分割的实现方法。首先，本文从核心算法 UNet++ 和 DeepLabv3+ 入手，为读者讲解了算法的相关知识；随后，本文讲述了如何基于这两个深度学习网络分别搭建有效的食管炎分割模型；最后，本文展示这两个分割模型的评估结果，清晰地展现了基于深度学习的食管炎检测方法所达到的效果。本文内容安排如下：

第一章为研究背景与意义，详细介绍了基于深度学习的食管炎检测方法的研究背景、目的和意义，包括相关领域的现状和问题。总的来说，本章引出其它章节，起到了抛砖引玉的效果。

第二章首先概述了本研究的核心深度学习网络的算法流程，包括 U-Net、UNet++、DeepLabv3 和 DeepLabv3+，并比较和分析 UNet++ 网络与 DeepLabv3+ 网络之间的结构差异及网络特点；接着，章节讲述了本次实验的算法评估指标，包括 IoU、mPA 和 Accuracy，这些指标将用以衡量算法在食管炎图像分割任务中的准确性和性能；最后，

章节阐述了用于训练 UNet++和 DeepLabv3+模型的核心训练参数，这些参数对于模型的训练和优化至关重要。

第三章主要展示了基于 UNet++和 DeepLabv3+的模型训练与评估的过程，具体包括模型搭建步骤、数据预处理、模型配置、模型训练和模型评估五个部分；随后，章节对这两个模型在食管炎检测任务中的评估结果进行了分析，分别讨论了基于 UNet++和 DeepLabv3+网络所构建的模型的性能和效果，并对这两者进行横向对比，探讨了可能的改进空间。

第四章作为总结章节，对本文的工作进行了总结，概括了研究的主要成果和贡献。同时，也展望了未来可能的研究方向和改进空间。



## 2 算法流程概述

### 2.1 算法总体概述

本次毕业设计主要基于 UNet++和 DeepLabv3+两个深度学习网络进行开发，下面本人将对两种算法及其相关算法进行简要概述，让读者有一个比较笼统的认识。

#### 2.1.1 U-Net 算法概括

在 2013 年及以前，卷积深度网络在许多视觉识别任务中的表现都显著优于其他深度学习算法。举例来说，在 Krizhevsky 等人<sup>[11]</sup>所进行的使用深度卷积神经网络的 Imagenet 分类任务中，该网络展现了其卓越的性能。然而，尽管卷积神经网络在深度学习领域中占据了较长时间的统治地位<sup>[12]</sup>，其性能却会受训练集和网络大小这两个因素限制。因此，对更大、更深的网络<sup>[13]</sup>的需求是显而易见的，这也是 U-Net 被提出的时代背景。

U-Net 是一种经典的深度学习网络，其核心思想是将卷积神经网络的编码器和解码器结合起来，形成一种 U 形的网络结构<sup>[14]</sup>，如图 4.1 所示。这种结构被广泛用于图像分割问题，因为它能够有效地捕捉图像中的上下文信息，并将其应用于像素级别的分类和分割任务。

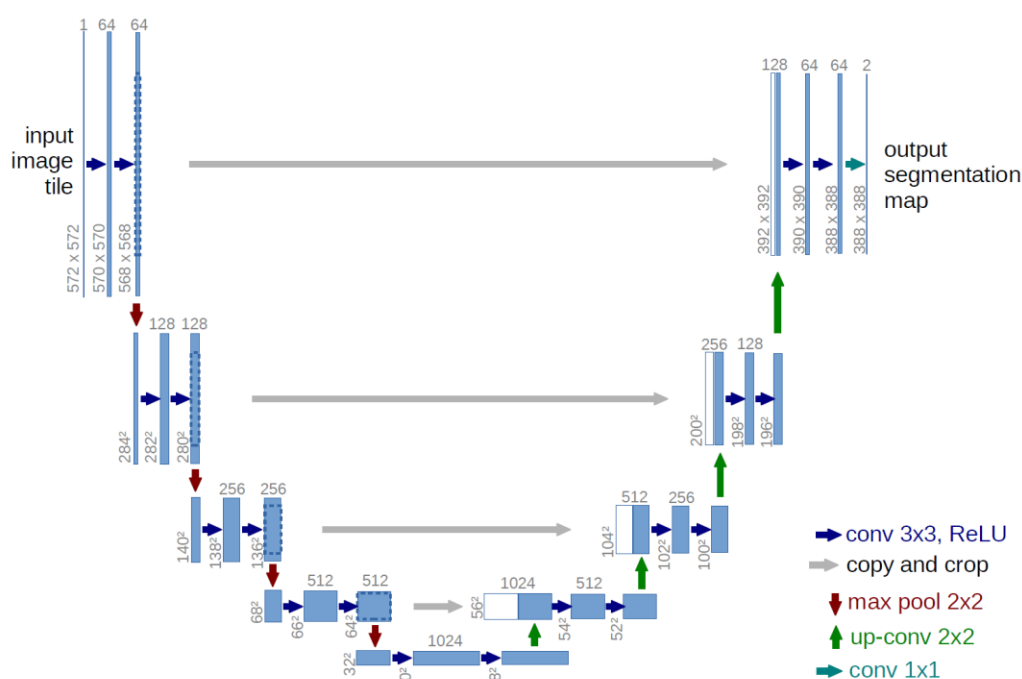


图 2.1 U-Net 的网络架构，摘自<sup>[15]</sup>

U-Net 网络具有以下特点：

(1) U 形网络结构：利用编码器和解码器之间的连接实现信息的跳跃传递。编码器部分通过卷积和池化操作逐步提取图像的高层抽象特征；而解码器部分则通过反卷积和上采样操作将特征图恢复到原始图像尺寸，并与编码器的特征图进行融合，从而输出精细的分割结果。

(2) 跳跃连接机制：利用该机制将编码器中的低层特征直接传递给解码器中的对应层，使得解码器能够获得更多的空间信息，进一步提高分割的精度。这种机制能够有效地解决深度网络在信息传递过程中的信息丢失问题，同时降低梯度消失对模型效果所带来的影响。

(3) 特征自动学习：采用卷积神经网络进行特征提取，自动学习图像中的特征表示，无需手动设计和提取特征。通过多层卷积和非线性激活函数，网络能够逐渐抽象出更高层次的特征表示，从而实现对图像中不同结构和纹理的有效表示和分割。

作为一种经典的图像分割模型，U-Net 在医学影像领域已经得到了广泛应用<sup>[16]</sup>。除此之外，它在其他方面<sup>[17]</sup>的分割任务中也表现出色，包括医学图像领域<sup>[18,19]</sup>，交通领域<sup>[20]</sup>和房屋设计领域<sup>[21]</sup>等。然而，相比 U-Net 而言，其改进算法 UNet++ 更加适合食管炎检测这一任务。在下一节中，本文将会对这一观点进行详细论述。

### 2.1.2 UNet++ 算法概括

在 U-Net 网络的基础上，Zhou 等人<sup>[22]</sup>提出了一种新颖且功能更加强大的医学图像分割架构，称为 UNet++。该架构基于深度监督编码器-解码器网络，其中编码器和解码器子网络通过一系列嵌套和密集的跳过路径连接。论文表明，当来自编码器和解码器网络的特征图在语义上相似时，该结构可以更轻松地处理学习任务。研究将 UNet++ 与 U-Net 和 Wide U-Net 架构在多个医学图像分割任务上进行了比较，结果表明，具有深度监督的 UNet++ 在 U-Net 和 Wide U-Net 上分别实现了 3.9 和 3.4 的平均 IoU 增益。

在食管炎检测方法这一课题中，UNet++ 相比于传统的 U-Net 模型具有显著的优势，这些优势使得 UNet++ 更适合应对食管炎检测任务的挑战：

(1) 更强的特征表示能力：UNet++ 在 U-Net 的基础上进行了改进，引入了多尺度特征融合的机制。通过在不同层级上进行特征融合，UNet++ 能够更全面地捕捉图像的上下文信息和多尺度特征，从而提高了特征的表示能力。在食管炎检测任务中，食管炎病灶的形态和大小可能会有很大的变化，因此，使用 UNet++ 可以更好地处理不同尺度和形态的炎症区域。

(2) 更好的边缘保持能力: UNet++在 U-Net 的解码器部分引入了连接跳跃机制,使得低层特征能够直接与解码器的对应层特征进行融合。这种跳跃连接机制能够帮助保持边缘信息,防止在分割过程中出现边缘模糊或丢失的情况。对于食管炎检测任务来说,精确地定位食管炎症区域的边界是非常重要的,因此 UNet++的边缘保持能力有助于提高食管炎检测的准确性。

(3) 模型的鲁棒性和泛化能力: UNet++通过引入更多的特征融合路径增加了网络的深度和复杂度。这种多路径的设计能够提升模型的鲁棒性和泛化能力,使得网络对于不同食管炎影像的变化和噪声具有更好的适应性。在实际应用中,食管炎影像可能受到噪声、光照变化等因素的影响,因此选用具有较强鲁棒性和泛化能力的 UNet++模型能够更好地应对这些挑战。

综上所述,UNet++相比于传统的 U-Net 模型更适合作为食管炎检测方法的核心模型,因为 UNet++具有更强的特征表示能力、边缘保持能力、泛化能力和鲁棒性,这些优势能够有效提升模型在食管炎检测任务中的准确性。因此,本研究将 UNet++作为食管炎检测模型的核心网络之一。

由于 UNet++自身的特性,基于此进行食管炎检测模型的搭建需要充分考虑数据质量、网络结构、损失函数和优化算法等方面的问题,才能实现更加准确、稳定、可靠的食管炎检测。同时,我们也应当考虑到,UNet++作为一个深度学习的经典模型,其性能是存在一定上升空间的。因此,本课题在完成 UNet++模型搭建与训练的基础上,基于另一个深度学习模型 DeepLabv3+也进行了检测模型的开发,意在分析不同的深度学习模型对于同一问题的解决程度差别,从而对计算机辅助食管炎检测产生更深的理解。

### 2.1.3 DeepLabv3 算法概括

DeepLabv3 是一个在语义分割任务中应用广泛的深度学习模型。该网络采用了空洞卷积技术来解决像素边界模糊的问题,通过扩大卷积核的感受野,有效提高了分割精度;此外,它还引入了自适应空洞卷积和多尺度训练等技术,使得模型能够适应不同大小的目标和场景;通过在训练过程中采用多尺度训练和分组正则化,它能够更好地避免模型的过拟合;另外,它所采用的全卷积网络结构使其能够处理任意大小的输入图像并输出相同大小的分割结果,这一特点使该模型变得更加实用,适用于绝大多数的分割需求。总体而言,DeepLabv3 具有较高的分割精度和鲁棒性,在城市场景分割和卫星图像分割等大规模图像分割任务中表现出色。

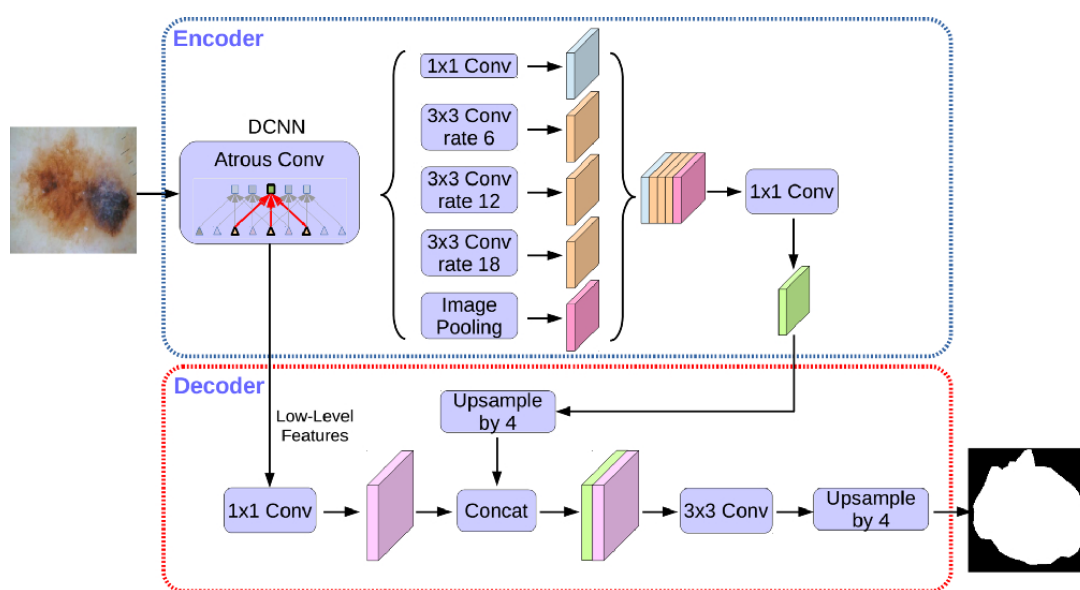


图 2.2 DeepLabv3 的经典架构, 摘自<sup>[23]</sup>

DeepLabv3 网络具有以下特点:

(1) **空洞卷积:** 通过引入空洞, 卷积核可以覆盖更大的感受野, 从而捕捉到更广阔的上下文信息。这对于解决语义分割中的像素边界模糊问题非常有效。相比传统的卷积方式, 空洞卷积可以在不增加计算量的情况下提高分割的准确性, 特别适用于处理具有大尺度语义结构的图像。

(2) **多尺度训练:** 通过引入了多尺度训练技术, 模型能够更好地应对不同大小目标和场景的分割需求。不同尺度的输入图像能够使模型学习到不同层次的语义信息, 这使得模型能够准确分割细小物体和大尺度场景, 提高了模型的适应性和泛化能力。

(3) **自适应空洞卷积:** 通过引入自适应机制, 模型的感受野进一步被增强。传统的空洞卷积在各个位置都使用相同的采样率, 但自适应空洞卷积可以根据图像内容自动调整采样率。这样, 模型可以在不同区域自适应地选择合适的感受野, 更有效地捕捉图像中不同尺度物体的细节信息, 提高了分割的精度和边界的清晰度。

(4) **全卷积网络:** 该结构使得模型能够处理任意大小的输入图像, 并输出与输入图像相同大小的分割结果。这种设计非常灵活, 增强了模型的实用性和普适性, 使其能够在各种应用场景下进行高效的像素级别分类。

(5) **ASPP 模块:** 利用多尺度金字塔池化模块, 模型能够捕捉图像中不同尺度的上下文信息。该模块通过并行的卷积和池化操作提取不同尺度下的语义特征, 并将它们融合起来, 以提高分割的准确性。

综上所述, DeepLabv3 通过空洞卷积、多尺度训练、自适应空洞卷积、全卷积网络和 ASPP 模块等关键技术实现了高效而准确的语义分割。然而, 相比 DeepLabv3 而言, 其改进算法 DeepLabv3+ 更加适合食管炎检测这一任务。在下一节中, 本文将会对这一观点进行更加详细的论述。

#### 2.1.4 DeepLabv3+算法概括

DeepLabv3+ 是对 DeepLab 系列的改进和扩展, 在分割任务中具有出色的性能, 尤其在语义分割领域, 被广泛应用于人物分割、车辆识别和医学图像分割。该网络的核心思想是通过结合空洞卷积和空间金字塔池化模块来解决分割任务中的像素边界模糊和多尺度信息捕捉的问题。总体而言, DeepLabv3+ 具有较高的分割精度和鲁棒性, 能够有效地捕捉多尺度上下文信息、提高感受野, 并准确地进行图像分割。在医学图像分割等领域的应用中, DeepLabv3+ 已经展示出卓越的性能和应用潜力。

DeepLabv3+ 相比 DeepLabv3 更适用于食管炎检测任务的原因有以下几点:

(1) 改进的解码器模块: DeepLabv3+ 引入了可逆上采样网络技术作为解码器模块的一部分。传统的上采样方法可能导致信息丢失和模糊的分割边界, 而可逆上采样网络通过特殊的上采样技术避免了这些问题。对于食管炎检测任务来说, 准确的分割边界和细节信息对于确定炎症区域的精准位置至关重要。DeepLabv3+ 的改进解码器模块可以提供更精细的分割结果, 有助于更准确地检测食管炎症区域。

(2) 更大的感受野: DeepLabv3+ 在 ASPP 模块中对空间金字塔池化进行了优化, 扩大了网络的感受野。在食管炎检测任务中, 炎症区域的大小和形状可能各不相同, 因此模型需要具有较大的感受野来捕捉不同尺度下的语义信息。通过增强感受野, DeepLabv3+ 能够更好地理解图像中的上下文结构, 提高对食管炎症区域的分割准确性。

(3) 高效的计算速度: DeepLabv3+ 不仅提升了分割性能, 还在一定程度上改善了计算速度。在食管炎检测任务中, 处理大规模的医学图像可能需要耗费大量的计算资源 and 时间。DeepLabv3+ 的改进设计使得模型在不牺牲准确性的前提下能够更高效地运行, 提高了实时性和处理大规模数据的能力。

综上所述, DeepLabv3+ 相比 DeepLabv3 更适合食管炎检测任务, 因为它具有改进的解码器模块、更大的感受野和更快的计算速度。这些特性使得 DeepLabv3+ 能够更准确地分割食管炎症区域, 并在处理大规模医学图像时具有更好的实用性和适应性。

#### 2.1.5 UNet++网络与 DeepLabv3+网络比较与分析

UNet++ 和 DeepLabv3+ 是在图像分割领域广泛应用的两个深度学习网络, 它们在结构和工作原理上存在一些显著的区别。

UNet++是基于 U-Net 模型的改进版本，它在 U-Net 的编码器-解码器结构基础上引入了密集跳跃连接，还使用了级联的 U-Net 模块，使网络能够逐渐提取更丰富的特征表示，并在解码器中使用自注意力机制来提升分割的准确性。因此，UNet++适用于处理小目标和边界模糊等情况，在小型医学图像分割任务中取得了很好的效果。

与 UNet++不同的时，DeepLabv3+结合了空洞卷积、空间金字塔池化层、ASPP 和解码器，利用可逆上采样网络来避免传统上采样方法中的信息丢失。因此，DeepLabv3+在多尺度信息捕捉和像素级别分类方面表现出色，适用于大规模图像分割任务。

由上文可知，这两个网络的主要区别在于，UNet++适用于小目标和边界模糊等情况，DeepLabv3+则侧重于大规模图像分割任务，因此，研究者们需要根据具体的任务需求和数据特点来选择网络结构。

尽管 DeepLabv3+和 UNet++都是医学分割方面的常用模型，但它们各有其原理及适用场合。所以，在食管炎检测这一任务中，选用 UNet++和 DeepLabv3+分别搭建模型并进行横向对比具有重要的必要性和意义。

首先，UNet++和 DeepLabv3+是两种在图像分割领域广泛应用且具有卓越性能的深度学习模型。它们都能够较好地解决图像分割中的挑战，但在具体任务和数据集上的表现可能有所不同。因此，通过横向对比这两个模型在食管炎检测任务上的效果，可以评估它们的适用性和优劣之处。

其次，食管炎检测是一项关键的医学任务，准确的图像分割对于确定食管炎的位置和程度至关重要。选用不同的模型进行对比可以帮助我们了解它们在食管炎检测中的优势和局限性。通过对比它们的检测结果和性能指标，可以为医生和研究人员提供更全面的参考，选择最适合食管炎检测的模型。

此外，横向对比不仅可以评估模型的性能，还可以揭示它们的特点和工作原理。UNet++和 DeepLabv3+在网络结构、特征提取方式、上采样方法等方面存在差异，对它们的对比分析可以帮助我们深入理解模型的设计思想和优化策略。这有助于推动图像分割领域的研究和发展，并为未来的模型设计提供启示和借鉴。

综上所述，通过在食管炎检测任务中选用 UNet++和 DeepLabv3+分别搭建模型，并进行横向对比，可以全面评估它们在特定任务中的性能、优劣和适用性，为医学领域的图像分割研究提供宝贵的参考和指导。这有助于改善食管炎检测的准确性和效率，并推动深度学习在医学图像分析中的应用和发展。

## 2.2 算法评估指标

### 2.2.1 IoU 指标

**IoU**（Intersection over Union）指标是用于评估图像分割模型性能的一种常见指标，通过计算模型预测分割结果与真实分割结果的交集与并集之比来衡量模型的分割精度。具体而言，对于每个像素点，分割模型会将其预测为属于某一类别，然后将所有预测结果与真实结果进行比较，计算它们的交集与并集。**IoU** 的值在 0 到 1 之间，1 表示模型预测完全正确，0 表示预测完全错误。

在基于深度学习的食管炎检测方法中选择 **IoU** 指标进行模型评估是非常合适的。首先，**IoU** 指标可以量化模型分割精度，帮助研究者和医生确定模型的性能，评估其在临床实践中的适用性；其次，**IoU** 指标与食管炎检测任务的要求相符，该指标可以精确地量化分割结果与真实结果的重叠程度，为食管炎的诊断和治疗提供更可靠的依据。

综上所述，**IoU** 指标是一种可靠的评估图像分割模型性能的指标，对基于深度学习的食管炎检测方法的模型评估环节具有重要意义。因此，本研究采用 **IoU** 值作为主要的模型评估指标，用以衡量模型在食管炎检测方面的性能。

### 2.2.2 mPA 指标

**mPA**（Mean Pixel Accuracy）同样是一种常用的图像分割评估指标。它计算了模型输出分割结果与真实分割结果之间每个像素的匹配情况，然后取平均值得到整个图像的像素级别的准确率。**mPA** 可以很好地衡量模型对每个像素的分类能力，尤其适用于处理类别均衡的数据集。当数据集中某些类别的数量明显少于其他类别时，使用 **IoU** 等评估指标可能会导致评估结果出现偏差。而 **mPA** 指标可以避免这种情况，并更全面地反映模型在像素级别上的性能。

在基于深度学习的食管炎检测方法中，选择 **mPA** 指标进行模型评估同样是合理的。因为在食管炎图像分割任务中，正负样本类别不均衡，且存在一些细小的病变区域，这些区域对整体的评估结果影响较大。使用 **IoU** 等评估指标容易低估模型的性能。而使用 **mPA** 指标可以更好地衡量模型的性能，特别是在处理类别不均衡的情况下。

综上所述，**mPA** 在模型评估方面可以很好地作为 **IoU** 评估值的辅助指标，更全面地衡量模型的效果。因此，本研究选取 **mPA** 作为模型评估的指标之一。

### 2.2.3 Accuracy 指标

准确率（Accuracy）表示了分类器正确分类的样本数与总样本数之比。然而，在医学图像分割任务中，样本中通常存在大量的背景像素，这些像素数量远大于目标区域像

素。因此，即使模型完全忽略目标区域，其准确率也可能非常高。这就是为什么在基于深度学习的食管炎检测方法中选用准确率指标进行模型评估不太合理的原因。另外，使用准确率指标还不能区分出模型的假阳性和假阴性的情况，而这种情况在医学图像分割任务中是需要被考虑到的。因此，为了更好地评估模型的性能，我们通常采用其他更合适的指标，例如 IoU 和 mPA 等。

综上所述，Accuracy 这一评估指标并不适合医学图像分割任务。因此，本研究并不将其作为模型评估的核心指标。

## 2.3 算法训练参数

### 2.3.1 UNet++核心训练参数

在基于 UNet++ 的分割模型训练过程中，研究者需要对以下几个参数进行调整和优化，从而提升模型的性能：

(1) **Deep\_Supervision**: 是否使用深度监督训练方式。在 UNet++ 中，深度监督可以提高模型的鲁棒性和稳定性，更好地利用中间层的特征信息。在食管炎分割任务中，使用 Deep\_Supervision 可以提高模型的精度和稳定性。

(2) **Epochs**: 模型训练的轮数。在食管炎分割任务中，Epochs 需要设置到一个足够大的值，以便让模型充分学习数据的特征。但是过多的 Epochs 可能导致模型过拟合，需要进行调整以获得最佳的性能。

(3) **Batch\_Size**: 每个训练批次中包含的样本数。在食管炎分割任务中，Batch\_Size 需要适当设置，以便在保证训练速度的同时，获得更好的模型性能。

(4) **Arch**: UNet++ 网络的结构。不同的网络结构具有不同的性能和适用场景。在本任务中有两种可选的网络结构，分别为 Nested U-Net (UNet++) 和 U-Net。

### 2.3.2 DeepLabv3+核心训练参数

在基于深度学习的食管炎检测任务中，使用 DeepLabv3+ 架构可以使模型具有优秀的性能。以下是几个 DeepLabv3+ 的核心训练参数及其在该模型训练过程中的作用：

(1) **Init\_Epoch**: 初始训练轮数。这个参数指定网络开始进行训练之前要运行多少个训练轮数。它通常设置为一个较小的值，以便网络可以对数据集进行一些初始学习。

(2) **Freeze\_Epoch**: 冻结训练轮数。在网络的整个训练期间中，有时需要冻结特征提取器的层数，只训练顶层的分类器部分。这个过程是通过 Freeze\_Epoch 这一参数实现的。该阶段有助于在初始学习阶段保持底层特征提取器的稳定性，避免权重调整过大。



(3) **Unfreeze\_Epoch:** 解冻训练轮数。这个参数指定从哪个训练轮数开始, 逐渐解冻特征提取器中的一层或几层, 以便整个网络可以进行端到端的微调。

(4) **Freeze\_Batch\_Size:** 冻结训练批次大小。这个参数指定在冻结阶段中训练使用的批次大小。通常, 由于冻结阶段的训练主要针对顶层的分类器, 使用较小的批次大小即可达到效果。

(5) **Unfreeze\_Batch\_Size:** 解冻训练批次大小。这个参数指定在解冻阶段中训练使用的批次大小。通常, 解冻阶段需要更大的批次大小以适应整个网络的训练。

(6) **Freeze\_Train:** 是否冻结特征提取器层的训练。如果设置为 **True**, 则特征提取器层的权重在冻结阶段将被锁定, 只训练顶层的分类器部分。

(7) **Backbone:** 用于特征提取的网络架构。这个参数指定了网络中使用的特征提取器, 在本研究中可选用两种预训练网络, 分别是 **Xception** 和 **MobileNet**。

## 3 模型训练与评估

### 3.1 基于 UNet++ 的模型训练与评估

#### 3.1.1 模型搭建步骤

UNet++模型的搭建步骤涵盖了数据预处理、模型选择和配置、模型训练和模型测试和评估四个关键步骤。在以下几节中，本文将对这些步骤进行详细阐述。具体步骤列举如下：

(1) 进行数据预处理。这一步骤的目的是准备用于训练和测试的食管炎原始图像及标记数据。针对标记数据，研究者需要对其进行预处理以符合模型的输入要求。通常情况下，原始的灰度图像会被处理成由 0-1 范围的像素值组成的图像，以适应模型的训练和评估过程。

(2) 选择 UNet++ 作为基础模型并进行配置。UNet++ 是在 U-Net 模型的基础上进行改进的，它具有密集跳跃连接和级联 U-Net 模块的特点。根据具体需求和数据特点，研究者需要对其进行超参数的配置。

(3) 进行模型训练。在这一步骤中，研究者需要使用经过预处理的数据集对 UNet++ 模型进行训练。在训练过程中，研究者通过最小化损失函数来优化模型，使其能够准确地学习和预测食管炎的分割结果。在模型的训练过程中，研究者可以根据训练集和验证集的损失值和精度等指标对模型进行调整和优化。

(4) 进行模型的测试和评估。在模型训练完成后，研究者需要使用预留的测试集对训练好的 UNet++ 模型进行测试和评估。通过输入测试图像，并观测模型对食管炎的分割结果，研究者能够对模型的性能有一个总体的了解。具体评估指标包括 IoU、mPA 和 Accuracy 等，用于量化模型的性能和准确性。

#### 3.1.2 数据预处理

首先，研究者需要对来自大连中心医院的食管炎数据集进行必要的的数据预处理，以便后续的模型训练。数据预处理步骤如下：

(1) 读取图像和掩码：使用 For 循环遍历每个样本的文件路径，并通过 `cv2.imread` 函数读取样本的图像和掩码。

(2) 控制图像通道和大小：根据图像的通道数和尺寸进行相应的处理。首先判断图像是否为灰度图，如果是，则将其复制为三通道图像。然后检查图像是否包含四个通道，如果是，则只保留前三个通道。最后，使用 `cv2.resize` 函数将图像和掩码的尺寸调整为指定的大小。

(3) 保存图像和掩码: 使用 `cv2.imwrite` 函数将处理后的图像和掩码保存到指定的文件夹中。掩码的像素值被乘以 255 并转换为无符号 8 位整数类型。

该数据预处理的目的是将原始图像和掩码调整为统一的大小, 并将它们保存到特定的文件夹中, 以供后续训练使用。这种预处理有助于确保输入数据的一致性, 使其能够适应模型的输入要求。此外, 将掩码转换为二值图像有助于在模型训练中更好地定义和区分目标区域。

### 3.1.3 模型配置

在处理好数据集之后, 研究者需要对模型的环境进行配置。基于深度学习的食管炎检测方法的软件、硬件和服务器的选择展示如下:

(1) 编程语言和库: 使用 Python3 作为主要编程语言, 依托深度学习库 TensorFlow、PyTorch 和 Kera 所提供的丰富工具和算法来构建和训练深度学习模型。

(2) 硬件选择: 在本次研究中使用了 TITAN 服务器, 其中包括 9 个 TITAN V 12G GPU, 这些 GPU 提供了强大的并行计算能力, 可以加速深度学习模型的训练过程。

(3) 操作系统: 使用 Ubuntu 16.04 作为操作系统, 这是一种常用的 Linux 发行版, 提供了稳定和可靠的环境来支持深度学习任务。

(4) 集群训练: 使用 ICCD 服务器集群进行模型训练。Xshell 7 是一种常用的 SSH 客户端, 它可以与远程服务器建立安全连接, 方便进行代码上传、环境配置和模型训练。

(5) 服务器配置: TITAN 服务器具有 48 个核心的 CPU (E5-2650 v4 @ 2.20GHz) 和 260GB 的内存, 这提供了强大的计算和存储能力, 适合大规模深度学习任务。

在配置完成后, 使用 Python 编写深度学习模型的代码, 并利用所选的深度学习库构建和训练模型。通过 Xshell 7 连接到 ICCD 服务器集群, 上传代码和数据集, 并在 TITAN 服务器上进行模型训练。使用 GPU 加速, 从而更快地完成模型训练, 并获得更准确的食管炎检测结果。

完成必要的环境配置之后, 接着需要对模型的相关训练参数进行合理的配置。模型配置部分通过代码定义了两个模型: U-Net 和 Nested U-Net。

首先介绍一下 U-Net 模型的相关配置。它接受一个参数 `Num_Classes` 以指定需要分割的类别数, 以及 `Input_Channels` 以指定输入图像的通道数。在模型的构造函数, 一系列的卷积块被定义以用于构建编码器和解码器。编码器部分包含了从输入图像到底层特征的卷积块, 而解码器部分则包含了从底层特征逐渐扩展回原始图像尺寸的卷积块。在编码器部分, 代码通过定义 `Nb_Filter` 列表来指定每个卷积块的输出通道数。在解码器部分, 模型采用了池化层和上采样层分别用于下采样和上采样操作。最后, 代码通过 `Final` 卷积层的构建将解码器的输出特征图映射到指定的类别数 `Num_Classes` 上。

接下来介绍一下 Nested U-Net 模型的配置，该模型又名 UNet++，是本次食管炎检测算法的核心算法之一，它与 U-Net 类似，但引入了更多的连接和层级以及深度监督机制。在解码器部分，代码采用了多个层级的连接操作，用于将编码器的特征图与解码器的对应层级连接起来。这种嵌套的连接结构有助于更好地利用不同层级的特征信息，并提高分割性能。此外，如果设置了 Deep\_Supervision 参数为 True，则模型会在不同层级上输出预测结果。在 Nested U-Net 的构造函数中，我们可以看到四个 Final 卷积层，它们分别对应不同层级的输出。这种深度监督机制允许在训练和评估过程中利用多个层级的预测结果，从而提高整体分割性能。

总的来说，通过配置不同的卷积块、连接操作和深度监督机制，U-Net 和 Nested U-Net 模型能够有效地进行图像语义分割，捕捉图像的语义信息并生成准确的分割结果。

### 3.1.4 模型训练

表 3.1 UNet++模型训练过程中部分参数与 IoU 的关系

Arch	Deep_Supervision	IoU
Nested U-Net	True	0.6023
Nested U-Net	False	0.5978
U-Net	True	0.5841
U-Net	False	0.5728

根据给出的模型训练参数和 IoU 值的关系，我们可以进行以下分析：

(1) Deep\_Supervision 在食管炎检测任务中的重要性：Deep\_Supervision 是一种训练技巧，通过在网络中引入多个预测分支，并在这些分支上计算损失函数，可以在不同层次上提取特征和预测结果。这种多层次的监督有助于减轻信息传播的障碍，提供更多的反馈信号，使网络能够更好地学习和调整参数，从而提高模型性能。可以观察到，在两种模型中，使用 Deep\_Supervision 都带来了更高的 IoU 得分。这表明在食管炎检测任务中，使用 Deep\_Supervision 能够提高模型的性能表现。

(2) Nested U-Net 相比于 U-Net 在食管炎检测效果上的优越性：Nested U-Net 是 U-Net 的改进版本，它通过添加嵌套路径和跳跃连接来增加网络的表示能力和上下文信息的利用。这使得 Nested U-Net 能够更好地捕捉图像中的细节和语义信息，从而优化了模型在食管炎检测任务中的表现。可以观察到，在使用或不使用 Deep\_Supervision 的情况下，Nested U-Net 模型的 IoU 得分均高于对应的 U-Net 模型的 IoU 得分。这表明在食管炎检测任务中，Nested U-Net 相比于 U-Net 具有更好的性能。

综上所述，Deep\_Supervision 在食管炎检测任务中起着重要的作用，能够提高模型的性能。此外，Nested U-Net 相比于 U-Net 在食管炎检测效果上具有优越性，可以更好地捕捉图像细节和语义信息，从而提升模型的准确性。

### 3.1.5 模型评估

以表现最佳的参数组合（Deep\_Supervision = True, Arch = Nested U-Net）所训练出的 UNet++模型为例，模型评估结果展示如下：

（1）IoU = 60.23;

（2）mPA = 72.40.

该模型在食管炎分割任务上的 IoU 指标为 60.23，说明该模型在分割任务上的表现较好。该模型在食管炎实拍照片上达到的分割效果如图 3.1，3.2，3.3 所示。




图 3.1 实拍病例照片，由大连中心医院提供



图 3.2 手工标注结果，由大连中心医院提供



图 3.3 UNet++模型标注结果

可以看到，在食管炎图像分割任务中，UNet++网络所标注的炎症范围大致与手工标注相同，但在边界上明显没有手工标注的清晰明确，同时，UNet++网络忽略了较小的炎症范围，不将其标注出来。

这种情况主要是因为 UNet++网络在图像分割任务中的设计特点所导致的。UNet++网络是一种层级嵌套的图像分割模型，其在处理输入图像时，先将其分解为多个分辨率下的特征图，然后再通过级联的方式将这些特征图进行融合，最终输出分割结果。在这个过程中，由于特征图的分辨率不同，导致在分割结果的边界处可能存在信息缺失或者模糊的情况。同时，UNet++网络的设计中还包含降采样操作，这也可能会导致在处理较小的炎症范围时信息的丢失。因此，这些设计特点可能会导致 UNet++网络在边界处分割效果不如手工标注，同时忽略较小的炎症范围。

因此，在肯定 UNet++网络在 IoU 值上较好的表现的同时，该网络自身的局限性也是值得注意的。U-Net 在网络结构上较为简单，由编码器和解码器两部分组成，没有使用像 ResNet 等预训练模型作为其 Backbone。另外，U-Net 采用了较少的参数和较小的模型大小，虽然训练速度较快，但相对来说容易出现欠拟合的情况。在食管炎检测这一任务中，由于存在一些复杂的情况，如遮挡、纤维化等，欠拟合可能导致模型无法有效地捕捉到这些复杂的特征。

综上所述，UNet++在食管炎检测任务上的性能虽然有限，但其训练速度优势仍然非常明显。基于给定的模型训练参数和评估结果，可以得出该 UNet++模型在食管炎分割问题上表现较为良好的结论。

## 3.2 基于 DeepLabv3+ 的模型训练与评估

### 3.2.1 模型搭建步骤

在具体搭建步骤方面，DeepLabv3+ 与 UNet++ 类似，此处不再赘述。在以下几节中，本文将对 DeepLabv3+ 模型的搭建步骤进行详细阐述。

### 3.2.2 数据预处理

与 UNet++ 的数据预处理类似，DeepLabv3+ 的预处理具体步骤如下：

(1) 数据集准备：确保数据集中包含两个文件夹，分别包含原始的食管炎图像和相应的标签图像。

(2) 数据集划分：根据给定的 `Trainval_Percent` 和 `Train_Percent` 参数，确定训练集、验证集和测试集的划分比例。当前的设置是将整个数据集作为训练集和验证集，没有单独划分测试集。

(3) 生成文件列表：根据划分得到的训练集和验证集的索引，将对应的图像文件名保存到相应的文件列表中。

(4) 检查数据格式：使用生成的文件列表对数据集进行检查，确保数据集中的标签图像是灰度图像或八位彩色图像，并统计各个像素值的数量。

总结来说，在 DeepLabv3+ 模型中，数据预处理的目的是为了准备训练和验证所需的文件列表，并确保数据集的格式符合模型的要求。这些预处理步骤为后续的模型训练和评估提供了必要的数据基础。

### 3.2.3 模型配置

环境配置方面，DeepLabv3+ 模型的步骤与 UNet++ 相同，此处便不再赘述。

以下是 DeepLabv3 模型配置中重要的步骤和参数：

(1) 定义模型架构并添加模型层：使用 Keras 的 `Sequential` 模型类来定义模型的架构，使用 `model.add()` 函数向模型中添加不同类型的层。

(2) 编译模型：在训练之前，使用 `model.compile()` 函数来配置模型的学习过程，使用该函数配置优化器、损失函数和评估指标。

(3) 配置其他模型参数：对其他必要的参数进行初始化，如输入形状、激活函数和正则化相关信息等。

当在模型配置中选择主干网络时，需要从 MobileNet 和 Xception 之间选择，这两个网络都是用于图像分类和特征提取任务的流行卷积神经网络架构。

**MobileNet** 是一种轻量级的卷积神经网络，旨在在计算资源受限的设备上实现高效的图像分类和特征提取。它通过使用深度可分离卷积来减少计算量。该卷积将标准卷积操作分解为深度卷积和逐点卷积两个步骤，从而显著减少参数量和计算成本，同时保持较好的性能。而 **Xception** 是一种基于 **Inception** 架构思想的深度卷积神经网络，它通过使用深度可分离卷积将 **Inception** 模块中的标准卷积替换为深度卷积，进一步提高了模型的性能和效率。

这两个主干网络可根据应用需求进行选择。**MobileNet** 适用于资源受限的设备和对计算效率要求较高的场景，而 **Xception** 则在性能和准确率方面表现出色。因此，在本次 **DeepLabv3+** 的模型搭建过程中，将分别使用 **MobileNet** 和 **Xception** 这两个主干网络，以期横向比较这两个主干网络在完成同一食管炎分割任务时所展现的效果。

### 3.2.4 模型训练

表 3.2 DeepLabv3+模型训练过程中 Backbone 与 IoU 的关系

Backbone	IoU
Xception	0.7943
MobileNet	0.6871

根据上表提供的信息，**DeepLabv3+** 模型训练过程中分别选择了 **MobileNet** 和 **Xception** 作为主干网络。结果显示，使用 **MobileNet** 作为主干网络时，模型的 **IoU** 值为 0.6871，而使用 **Xception** 时，模型的 **IoU** 值为 0.7943。根据这些结果，可以得出以下分析：

（1）总体表现：使用 **Xception** 作为主干网络的模型在该食管炎检测任务中表现更好，其 **IoU** 值较高；使用 **MobileNet** 作为主干网络的模型在该任务中表现较差。

（2）主干网络的影响：**Xception** 是一种更深层次的网络结构，具有更强的建模能力和表达能力，可以更好地捕捉图像中的细节和特征。在食管炎检测任务中，**Xception** 的性能优势能够更好地提取和分析与食管炎相关的细微特征，从而使模型具有更高的 **IoU** 值。相比之下，**MobileNet** 是一种轻量级网络，相对而言在复杂任务中的表现有所限制。在该任务中，由于图像中存在更复杂的特征和结构，**MobileNet** 无法充分地捕获和表示这些特征，导致模型表现出较低的 **IoU** 值。

需要注意的是，仅从 **IoU** 值来看不能完全确定哪个主干网络更好，在实际情况中需要综合考虑其他指标来选择合适的主干网络。



整个训练过程主要分为两个步骤——冻结训练阶段和解冻训练阶段，由 `Init_Epoch`、`Freeze_Epoch` 和 `Unfreeze_Epoch` 三个参数控制，该机制主要是为了适配不同的机器性能。冻结阶段所需要的显存比较小，比较适合性能较差的机器进行模型训练。因此，当电脑的性能不支持模型进行更复杂的训练时，可以适当将 `Freeze_Epoch` 调大，使其与 `UnFreeze_Epoch` 的差值更小，增加冻结训练的比重。但是，该操作也会对最后的 IoU 指标产生较大的影响。

表 3.3 DeepLabv3+模型训练过程中 Epoch 与 IoU 的关系

Init_Epoch	Freeze_Epoch	Unfreeze_Epoch	IoU
0	50	100	0.7943
0	60	100	0.7349
0	80	100	0.7120
0	100	100	0.6932

根据上表提供的信息，研究者在 DeepLabv3+ 模型训练的过程中逐渐增加了 `Freeze_Epoch` 的大小，以使其更接近 `Unfreeze_Epoch` 的值。结果显示，随着 `Freeze_Epoch` 值的增大，模型评估指标 IoU 的值也同时下降了，模型的 IoU 值从最佳效果 0.7943 逐步降到了 0.6932。根据这些结果，可以得出以下分析：

（1）总体表现：当 `Freeze_Epoch` 的值较小，为 50 时，模型在该食管炎检测任务中表现更好，其 IoU 值较高；当其值提高时，模型在该任务中表现较差。

（2）冻结训练的影响：冻结阶段过程中，模型的主干网络被冻结了，因此特征提取网络不会发生较大的改变，只会进行网络结构的小幅调整。因此，当 `Freeze_Epoch` 取较大值时，模型训练过程中占用的显存减小，相应的，模型的效果也变差了。

（3）解冻训练的影响：解冻阶段过程中，此时模型的主干网络不再被冻结了，因此特征提取网络会随着训练过程发生较大的改变。因此，当 `Freeze_Epoch` 取较小值时，模型训练过程中占用的显存减小，相应的，模型的效果也变好了。

需要特别注意的是，尽管在上表所展示的训练过程中，解冻训练占比越大，模型效果越好，但这不是绝对的。由于 `Freeze_Epoch` 取值过程中是从 50 开始增加的，本身就存在一段时间的冻结训练，因此随着该参数值的继续增加，模型性能倾向于变得更差。但是如果完全取消冻结训练，从第一轮就开始解冻训练，反而会使模型结构变化过快而难以收敛到一个最佳的状态。因此，在 DeepLabv3+ 的模型训练过程中，一般会采用部

分冻结训练，部分解冻训练的训练方式，并且先冻结主干训练后解冻训练，从而使模型达到较好的性能效果。

### 3.2.5 模型评估

以采用表现最佳的参数组合（Backbone = Xception, Init\_Epoch = 0, Freeze\_Epoch = 50, Unfreeze\_Epoch = 100）所训练出的 DeepLabv3+模型为例，如图 3.4, 3.5 所示，前者展示的是手工标注的食管炎炎症范围，后者展示的是经过训练的模型在原始图像上标注的炎症范围。可以看出，在这个样例中，该模型的标注范围与实际炎症范围相似度很高，达到了较高的图像分割精度。




图 3.4 手工标注的食管炎炎症区域，由大连中心医院提供




图 3.5 DeepLabv3+模型标注的食管炎炎症区域

模型评估结果:

(1)  $\text{IoU} = 79.43$ ;

(2)  $\text{mPA} = 86.43$ .

可以看出,DeepLabv3+模型在食管炎分割任务上表现出很高的分割精度和清晰准确的分割边界,这说明该模型具有强大的特征提取和特征融合能力,可以很好地适应各种大小和形状的病灶,从而得到高质量、清晰准确的分割结果。

综上可得,该 DeepLabv3+模型经过训练集上一百轮的训练后,在  $\text{IoU}$  指标方面达到了 79.43,  $\text{mPA}$  上达到了 86.43,总体来说模型效果符合预期,达到了非常高的分割精度,能够很好地完成该医学分割任务。

### 3.3 评估结果分析

DeepLabv3+和 UNet++都是目前在图像分割领域被广泛应用的深度学习模型,但它们在设计和原理上有很大的差别,因此在不同的任务上表现也会有所不同。

在食管炎图像分割任务上,DeepLabv3+达到 79.43 的  $\text{IoU}$ ,而 UNet++只有 60.23,主要原因可以归结为以下两点:

(1) 网络结构: DeepLabv3+使用空洞卷积、ASPP 模块和多尺度输入等技术,有利于模型捕捉不同尺度的特征和细节信息,提高分割精度。而 UNet++的网络结构相对简单,只使用了级联的 U-Net 结构,并没有引入太多的特殊技术。

(2) 数据增强: DeepLabv3+在训练过程中采用了多种数据增强技术,如旋转、翻转、缩放等,增加了训练集的多样性,有利于提高模型的泛化能力。而 UNet++的数据增强相对简单,只做了一些基本的翻转和缩放。

总体来说,DeepLabv3+在食管炎分割问题上表现更优秀,它利用了更先进的技术和更丰富的数据增强手段,在网络结构、训练参数和泛化能力等方面都有所优化。但是需要注意的是,选择模型还需要根据具体的任务需求和数据情况进行评估和调整。

## 4 总结与展望

### 4.1 本文工作总结

本文主要研究了基于深度学习的食管炎检测方法，以提高食管炎检测的准确率和效率。文章介绍了食管炎的临床意义和传统检测方法的局限性，进而提出了基于深度学习的食管炎检测方法的研究方向。

在实验部分中，研究者采用了 UNet++ 和 DeepLabv3+ 这两个基于深度学习的图像分割模型进行食管炎检测，比较了它们在分割准确性和边界精度等方面的表现。其中，研究结果显示，DeepLabv3+ 模型具有更好的分割精度，可以达到 79.43 的 IoU 值，分割边界也更加清晰准确；相比之下，UNet++ 模型分割精度较低，只能达到 60.23 的 IoU 值，且在边界清晰度方面表现不如 DeepLabv3+。

在训练参数方面，我们发现深度监督机制和 Backbone 的设置对模型的影响较大，启用深度监督机制并选择合适的主干网络可以显著提高模型的分割精度。

总的来说，本文通过基于深度学习的食管炎检测方法实验，实现了基于 UNet++ 和 DeepLabv3+ 的自动化食管炎检测，并达到了较高的分割精度和准确率，具有其研究意义和应用价值。未来，研究者将进一步探索如何提高基于深度学习的食管炎检测方法的性能，以更好地将深度学习技术应用于医疗领域。

### 4.2 本文工作展望

本文所介绍的基于深度学习的食管炎检测方法已经取得了很大的进展，但是仍然存在一些问题和挑战，下面是一些展望：

(1) 数据集的缺陷：目前的食管炎图像数据数量有限，而且其中大部分是由单一设备获取的，因此，这些数据可能存在偏差和局限性，导致训练出来的模型泛化能力不强。因此，我们需要更多且更具多样性的数据集来训练模型。

(2) 模型的改进：虽然基于深度学习的食管炎检测方法已经取得了不错的结果，但是仍然存在一些问题，例如对于边缘模糊的病变检测效果不佳等，因此需要研究更加有效的模型结构和训练方法来提升检测精度。

(3) 可解释性的提升：基于深度学习的模型往往是黑盒，对于模型输出结果的可解释性较差，这对于医疗领域来说是一个不利的因素。因此，需要进一步研究如何提高模型的可解释性，使得模型输出结果更具有说服力。

（4）实际应用的推广：虽然基于深度学习的食管炎检测方法已经取得了值得骄傲的进展，但是这些方法尚未在实际临床应用中得到广泛应用，因此需要进一步推广和落地。同时，还需要考虑如何解决隐私和安全等问题，以确保患者数据的安全性。

综上所述，本文所讨论的基于深度学习的食管炎检测方法仍然存在一些挑战和问题，但是我们相信，随着研究的深入和技术的进步，这些问题将逐渐得到解决，该领域的研究也将会取得更好的成果。

## 结 论

本文针对食管炎检测这一课题提出了基于深度学习技术的两种解决方法：基于 DeepLabv3+ 构建分割模型以及基于 UNet++ 构建分割模型。经过实验对比和分析，研究者得出以下结论：

首先，值得注意的是，在食管炎分割任务中，DeepLabv3+ 相比于 UNet++ 具有更好的性能。DeepLabv3+ 的炎症区域分割精度较高，分割边界也清晰准确。这归因于 DeepLabv3+ 采用的空洞卷积和 ASPP 模块，这些特点使其能够更好地处理图像中的长程依赖和多尺度特征，提高了分割精度。相比之下，UNet++ 在处理图像中的炎症边界和小目标炎症区域时表现不佳，这是因为 UNet++ 的上采样过程会导致信息的丢失和模糊，无法很好地还原图像的边缘和细节。

其次，我们也发现，在深度学习模型的训练中，调整 Backbone 和 Deep\_Supervision 等参数对模型表现有着重要影响。对于 DeepLabv3+ 模型，采用更先进的骨干网络可以提高模型表现，同时适当增加 Epochs 和 Batch\_Size 也能够带来性能的显著提升。而对于 UNet++ 模型，过大的 Batch\_Size 可能会导致内存溢出，训练速度变慢，从而影响模型收敛效果。

总之，本文通过实验比较分析，展示了深度学习在食管炎检测领域的应用和性能表现。未来，研究者可以就该课题探索更加先进的深度学习模型和更丰富的图像增强技术，进一步提高食管炎检测的准确性和效率。

## 参 考 文 献

- [1] Furuta G T, Katzka D A. Eosinophilic esophagitis[J]. New England Journal of Medicine, 2015, 373(17): 1640-1648.
- [2] Hua K L, Hsu C H, Hidayati S C, et al. Computer-aided classification of lung nodules on computed tomography images via deep learning technique[J]. OncoTargets and therapy, 2015: 2015-2022.
- [3] Cheng J Z, Ni D, Chou Y H, et al. Computer-aided diagnosis with deep learning architecture: applications to breast lesions in US images and pulmonary nodules in CT scans[J]. Scientific reports, 2016, 6(1): 1-13.
- [4] Zhang W, Li R, Deng H, et al. Deep convolutional neural networks for multi-modality isointense infant brain image segmentation[J]. NeuroImage, 2015, 108: 214-224.
- [5] Ciompi F, Chung K, Van Riel S J, et al. Towards automatic pulmonary nodule management in lung cancer screening with deep learning[J]. Scientific reports, 2017, 7(1): 46479.
- [6] Liauchuk V, Kovalev V, Kalinovskiy A, et al. Examining the ability of convolutional neural networks to detect lesions in lung ct images (deep learning)[C]//Computer Assisted Radiology and Surgery. 2017.
- [7] Havaei M, Davy A, Warde-Farley D, et al. Brain tumor segmentation with deep neural networks[J]. Medical image analysis, 2017, 35: 18-31.
- [8] Pereira S, Pinto A, Alves V, et al. Brain tumor segmentation using convolutional neural networks in MRI images[J]. IEEE transactions on medical imaging, 2016, 35(5): 1240-1251.
- [9] Siegel R L, Miller K D, Jemal A. Cancer statistics, 2018[J]. CA: a cancer journal for clinicians, 2018, 68(1): 7-30.
- [10] Dhungel N, Carneiro G, Bradley A P. Deep structured learning for mass segmentation from mammograms[C]//2015 IEEE international conference on image processing (ICIP). IEEE, 2015: 2950-2954.
- [11] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [12] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural computation, 1989, 1(4): 541-551.
- [13] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [14] Du G, Cao X, Liang J, et al. Medical image segmentation based on U-Net: A review[J]. Journal of Imaging Science and Technology, 2020.

- [15] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015: 234-241.
- [16] Sahiner B, Pezeshk A, Hadjiiski L M, et al. Deep learning in medical imaging and radiation therapy[J]. Medical physics, 2019, 46(1): e1-e36.
- [17] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. Annual review of biomedical engineering, 2017, 19: 221-248.
- [18] Al-Masni M A, Al-Antari M A, Choi M T, et al. Skin lesion segmentation in dermoscopy images via deep full resolution convolutional networks[J]. Computer methods and programs in biomedicine, 2018, 162: 221-231.
- [19] Chen L, Bentley P, Mori K, et al. DRINet for medical image segmentation[J]. IEEE transactions on medical imaging, 2018, 37(11): 2453-2462.
- [20] Liu X, Deng Z. Segmentation of drivable road using deep fully convolutional residual network with pyramid pooling[J]. Cognitive Computation, 2018, 10: 272-281.
- [21] Wu G, Guo Z, Shi X, et al. A boundary regulated network for accurate roof segmentation and outline extraction[J]. Remote Sensing, 2018, 10(8): 1195.
- [22] Zhou Z, Rahman Siddiquee M M, Tajbakhsh N, et al. UNet++: A nested U-Net architecture for medical image segmentation[C]//Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, Proceedings 4. Springer International Publishing, 2018: 3-11.
- [23] Azad R, Asadi-Aghbolaghi M, Fathy M, et al. Attention DeepLabv3+: Multi-level context attention mechanism for skin lesion segmentation[C]//Computer Vision - ECCV 2020 Workshops: Glasgow, UK, August 23 - 28, 2020, Proceedings, Part I 16. Springer International Publishing, 2020: 251-266.



## 修改记录

### (1) 毕业论文内容重要修改记录

#### 第一次修改记录:

第 27 页图 3-5, **修改前:** 用白色高亮标注炎症区域。

**修改后:** 用红色高亮标注炎症区域。

#### 第二次修改记录:

摘要, **修改前:** 食管炎是一种医学上十分常见的消化系统疾病, 它的诊断和治疗一直是医疗从业者所关注的问题。随着深度学习技术的发展, 基于深度学习的食管炎检测技术在医学图像处理中发挥着越来越重要的作用。

**修改后:** 食管炎是一种常见的消化系统疾病, 其诊断和治疗一直是医学工作者所关注的热点问题。随着深度学习技术的发展, 基于深度学习的图像分割技术在医学图像处理中逐渐发挥着越来越重要的作用。

#### 第三次修改记录:

DeepLabv3+模型训练部分, **修改前:** 只讨论了主干网络对训练结果的影响。

**修改后:** 追加了对冻结训练和解冻训练相关参数的讨论, 增加了表 3.3 以展现冻结训练对训练结果的影响, 并增加相关文字进行结果分析。

### (2) 毕业论文外文翻译修改记录

#### 第一次修改记录:

**修改前:** 未核对专业名词。

**修改后:** 查阅全文涉及的专业名词并替换成了更准确的翻译。

### (3) 毕业论文正式检测重复比

去除本人文献复制比: 2.5%;

跨语言检测结果: 0%;

去除引用文献复制比: 2.5%;

总文字复制比: 2.5%.

记录人(签字):

指导教师(签字):

## 致 谢

作为设计的最后一个环节，我想在论文的最后一部分感谢在完成设计过程中曾经帮助过我的人。

首先要感谢的是为我确定研究方向的杨鑫老师，感谢他给我指定了如此富有趣味性和挑战性的课题作为我的设计。还记得选题的时候，杨老师询问我想做什么类型的课题，我毫不犹豫的就选择了计算机视觉，而杨老师也非常尊重我的意见，为我确定了基于深度学习的食管炎检测方法研究与实现这一计算机视觉领域的研究课题。在完成该研究的过程中，我对计算机视觉这一研究领域的认识也得到了深化，这对我未来的学习研究有着很大的帮助。

接下来我想感谢我的学长房友江同学，是他在我设计遇到困难的时候不厌其烦的帮助我。这次设计是我第一次使用服务器来进行人工智能模型的训练，因此犯了很多低级的错误，没有学长耐心的指导，我不可能如此顺利地完成任务。在设计以外的情景中，学长也积极回答我的疑惑，为我的未来规划提供了参考性的建议。在我研究生期间，我会一直铭记学长对我的帮助和教导，继续努力提升自己的能力。

四年的本科生活要结束了，我也即将奔赴人生的下一个阶段。回首过去感觉也有很多遗憾，但我从未后悔我在专业方向的选择。虽然我现在在计算机方面的基础知识掌握和代码熟练度方面都有很大的提升空间，但我可以确定的是，计算机科学就是我最喜欢的方向，我为我选择了该专业并将从事相关领域的工作而感到自豪。希望未来的我能够继续学自己想学的东西，做自己想做的工作，过自己想过的生活。